Deep Learning GSLC – Part A: Analisis Konseptual

Nama: David Gaby Sahala Sinambela
NIM: 2802520293

1. Efek Regularisasi pada Batch Normalization

Batch Normalization menormalisasi aktivasi menggunakan rata-rata μ dan varians σ^2 yang dihitung dari setiap mini-batch (Slide 7). Karena isi batch diacak di setiap iterasi, nilai μ dan σ^2 selalu sedikit berubah, sehingga output satu gambar ikut bergantung pada gambar lain di batch yang sama. Ketergantungan ini menambahkan noise halus yang menyulitkan model menghafal data latih, sehingga muncul efek mild regularization (Slide 8). Namun, kata "often" pada Slide 8 menandakan Dropout tidak selalu bisa dihilangkan. Pertama, pada batch size besar, μ dan σ^2 sangat stabil sehingga noise hampir hilang dan efek regularisasinya tidak lagi cukup, terutama pada data kecil dengan classifier head besar. Kedua, pada batch size sangat kecil (misalnya 1–4), estimasi μ dan σ^2 terlalu bising sehingga pelatihan tidak stabil. Ketiga, Dropout yang diletakkan sebelum BN menggeser varians aktivasi antara mode train dan inference (variance shift), sehingga performa justru turun [8].

2. Degradasi Jaringan Dalam dan Formulasi Residual

Masalah degradasi bukanlah bentuk overfitting, sebab tingkat error training plain network 56 layer terbukti lebih tinggi dibandingkan varian 20 layer [1]. Slide 10 mencatat bahwa jaringan yang lebih dalam kadang berkinerja lebih buruk. Secara teori, penambahan layer harusnya mampu mempelajari identity mapping, tetapi optimizer kesulitan mengaproksimasi fungsi tersebut melewati tumpukan layer non-linear [1]. Residual block mengubah fokus pembelajaran menjadi $F(x) = H(x) – x$, dengan $H(x)$ sebagai pemetaan yang diinginkan, sehingga $y = F(x) + x$ (Slide 11). Identity mapping menjadi mudah dengan mendorong $F(x)$ ke nol. Saat backpropagation, gradiennya menjadi: $\partial L/\partial x = \partial L/\partial y \cdot (\partial F/\partial x + 1)$. Komponen "+1" dari skip connection mengalirkan gradien secara langsung. Pada Sesi 02, vanishing gradient timbul karena chain rule mengalikan banyak turunan kecil (juga disebut di Slide 10). Dengan skip connection, gradien mengalir secara aditif (lewat jalur +1), bukan hanya perkalian, sehingga layer awal tetap menerima sinyal belajar yang cukup [2].

3. Feature Extraction vs. Fine-Tuning

Dari sisi trainable parameters, Feature Extraction hanya melatih classifier head baru (5.130 parameter pada ResNet-18 untuk 10 kelas), sedangkan Fine-Tuning yang membuka layer4 dan fc melatih sekitar 8,4 juta parameter (±75% dari total 11,2 juta). Karena parameternya sedikit, Feature Extraction cocok untuk data terbatas (Slide 15), sementara Fine-Tuning membuka jutaan parameter sehingga butuh data lebih banyak agar tidak overfitting (Slide 28). Komputasi dan memori Feature Extraction lebih ringan karena backward pass dan state optimizer hanya untuk head, sedangkan Fine-Tuning menghitungnya untuk semua layer yang dibuka. Risiko destructive gradient updates hanya ada pada Fine-Tuning: head baru yang masih acak menghasilkan gradien besar yang dapat merusak fitur pretrained [3]. Kriteria praktisnya: mulai dari Feature Extraction (Slide 29); beralih ke Fine-Tuning bertahap dengan learning rate rendah (Slide 16) jika data cukup atau domain berbeda dari ImageNet, karena fitur layer akhir bersifat spesifik terhadap tugas asal [4].

4. Kaidah Penerapan Data Augmentation

Augmentation hanya diaktifkan pada train set karena tujuannya mensimulasikan data latih tambahan agar model lebih general (Slide 20). Validation dan test set berfungsi mengukur performa pada data asli, sehingga harus deterministik, hanya melalui resize, crop tengah, dan normalisasi. Jika data evaluasi ikut diacak, metrik berubah di setiap run, early stopping yang memonitor validation loss menjadi tidak stabil, dan perbandingan antar kondisi eksperimen tidak lagi adil. Augmentasi juga dilakukan setelah pembagian data, secara on-the-fly pada train set, agar tidak terjadi data leakage. Contoh transformasi yang tidak layak untuk pet breeds adalah ColorJitter dengan perubahan hue (Slide 21 hanya menyebut brightness dan contrast). Augmentasi aman jika label tetap terjaga [5], sedangkan warna bulu adalah ciri pembeda ras. Hue shift dapat membuat Russian Blue yang berbulu abu-kebiruan tampak cokelat kemerahan seperti Abyssinian, padahal labelnya tetap Russian Blue, sehingga model belajar dari pasangan gambar dan label yang keliru.

5. Mitigasi Catastrophic Forgetting

Catastrophic forgetting terjadi saat adaptasi berlangsung terlalu agresif sehingga pengetahuan bawaan tertimpa oleh pembelajaran tugas baru (Slide 28; [7]). Bobot pretrained sudah bagus untuk fitur umum ImageNet, tetapi optimizer hanya meminimalkan loss data baru tanpa ada yang menahannya menjauhi titik itu. Di awal fine-tuning, head baru masih acak sehingga gradiennya besar; jika learning rate tinggi, gradien ini ikut menggeser bobot backbone dan merusak fitur pretrained [3]. Mitigasi

pertama adalah differential learning rate: layer pretrained diberi learning rate kecil (1e-4 untuk layer4), head lebih besar (1e-3), sehingga fitur pretrained hanya bergeser sedikit sementara head belajar cepat (Slide 16). Mitigasi kedua adalah gradual unfreezing: latih head lebih dulu dengan backbone beku (Slide 29), lalu buka layer dalam bertahap karena layer terakhir memuat pengetahuan paling spesifik (Slide 16; [6]).

6. References

[1] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR), 2016, pp. 770–778. [Online]. Available: https://arxiv.org/abs/1512.03385

[2] K. He, X. Zhang, S. Ren, and J. Sun, "Identity mappings in deep residual networks," in Computer Vision – ECCV 2016, Lecture Notes in Computer Science, 2016, pp. 630–645. [Online]. Available: https://arxiv.org/abs/1603.05027

[3] A. Kumar, A. Raghunathan, R. Jones, T. Ma, and P. Liang, "Fine-tuning can distort pretrained features and underperform out-of-distribution," in Proc. Int. Conf. Learning Representations (ICLR), 2022. [Online]. Available: https://arxiv.org/abs/2202.10054

[4] J. Yosinski, J. Clune, Y. Bengio, and H. Lipson, "How transferable are features in deep neural networks?," in Advances in Neural Information Processing Systems (NeurIPS), 2014. [Online]. Available: https://arxiv.org/abs/1411.1792

[5] C. Shorten and T. M. Khoshgoftaar, "A survey on image data augmentation for deep learning," Journal of Big Data, vol. 6, no. 1, art. no. 60, 2019. [Online]. Available: https://doi.org/10.1186/s40537-019-0197-0

[6] J. Howard and S. Ruder, "Universal language model fine-tuning for text classification," in Proc. 56th Annual Meeting of the Association for Computational Linguistics (ACL), 2018, pp. 328–339. [Online]. Available: https://aclanthology.org/P18-1031/

[7] J. Kirkpatrick et al., "Overcoming catastrophic forgetting in neural networks," Proceedings of the National Academy of Sciences, vol. 114, no. 13, pp. 3521–3526, 2017. [Online]. Available: https://doi.org/10.1073/pnas.1611835114

[8] X. Li, S. Chen, X. Hu, and J. Yang, "Understanding the disharmony between dropout and batch normalization by variance shift," in Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR), 2019, pp. 2677–2685. [Online]. Available: https://arxiv.org/abs/1801.05134